


RAG

Retrieval-Augmented Generation

Cuando la IA deja de inventarse las cosas

Mar Izquierdo Vaquer · 27/05/2026 · Arquitectura RAG



Esto es peor que inventárselo.

Gemini — respuesta real

No dispongo de una base de datos interna y privada de corporaciones globales, por lo que no puedo darte con absoluta certeza el contacto directo...

Sin embargo, revisando información pública:

Nexus (España)

Teléfono RRHH: +34 937 205 969

Email RRHH: rrhh@nexus-spain.com

Nexus Group LATAM

Colombia: +57 1 300-2174 | info@nexusgroup.com.co

¿Qué acaba de hacer?

✓ Reconoció que no sabía

✗ Buscó empresas reales llamadas 'Nexus'

✗ Mezcló sus datos reales con tu empresa ficticia

✗ Sin ningún aviso

*Una empresa ficticia.
Contactos de empresas reales.*

Nexus Solutions no existe. Me la inventé ayer.

¿Qué es un LLM?

Large Language Model — lo que sabe y lo que no sabe



Ha leído una cantidad enorme de texto: libros, webs, código, artículos científicos, foros...



Aprendió patrones del lenguaje humano con miles de millones de parámetros.



Genera texto coherente, natural e inteligente — predice la siguiente palabra más probable.



Fue entrenado hasta una fecha concreta. Después de esa fecha: no sabe nada.

Entrenamiento



Noticias de hoy



Datos de tu empresa



Información privada

¿Por qué alucinan?

El malentendido más extendido sobre cómo funcionan los LLMs

Lo que creemos que hace

- Busca en su memoria
- Encuentra la respuesta correcta
- La devuelve con fiabilidad

Lo que realmente hace

- Predice la siguiente palabra
- Elige la más probable estadísticamente
- Repite hasta completar la respuesta

Su trabajo es generar texto coherente — no verificar si es verdad.

Tres problemas reales

Por qué un LLM solo es un riesgo en entornos empresariales

01

Conocimiento obsoleto

Fue entrenado hasta cierta fecha.
Nada posterior. Punto.

02

Sin contexto privado

No conoce tu empresa.
No leyó tu documentación.

03


Alucina con confianza

Cuando no sabe, inventa.
Y no avisa de que lo está haciendo.

Un LLM solo en una empresa no es simplemente poco útil — es un riesgo.

Embeddings — cómo las máquinas entienden

Texto → lista de números que captura el significado semántico



Los embeddings se crean automáticamente con modelos pre-entrenados. Nadie diseñó las dimensiones: emergieron solas del entrenamiento con millones de textos.

Aritmética semántica — lo que emerge

Una propiedad que nadie programó — la máquina descubrió leyendo texto humano

Aritmética semántica — emerge sola del entrenamiento



¿Por qué funciona esto?

El modelo aprendió que la distancia entre rey y reina es la misma que entre hombre y mujer.

No fue programado.

Emergió leyendo texto humano.

En RAG: la pregunta y los chunks viven en este mismo espacio.


Buscamos los más cercanos.

Similitud entre vectores — ángulo = relevancia

RAG compara el vector de la pregunta con todos los chunks — el ángulo decide la relevancia

Similitud coseno — cómo comparamos vectores

Ángulo pequeño → MUY SIMILARES Ángulo grande → POCO SIMILARES



RAG recupera los 4 fragmentos con mayor similitud — no los exactos sino los más cercanos en significado.

Vector Database — qué guarda realmente

No es una base de datos normal — está optimizada para búsqueda semántica

Vector Database — lo que realmente almacena



En este proyecto: ChromaDB — sin servidor, guarda en disco, cero configuración.

Chunks y Overlap — el arte de trocear documentos

El tamaño del chunk afecta directamente la calidad del retrieval

Chunks y Overlap — por qué troceamos los documentos


Documento original (PDF completo)

5 días de vacaciones. Estas deben solicitarse con 15 días de antelación mediante el formulario HR-04 disponible en el portal del empl




RecursiveCharacterTextSplitter

✗ Sin overlap (chunk_overlap = 0) — información se pierde en los cortes



✓ Con overlap (chunk_overlap = 64 chars) — contexto se preserva



El chunking malo arruina un RAG. El tamaño óptimo depende del tipo de documento.

RAG — la solución más simple posible

El problema no es el LLM. El problema es que no tiene los datos correctos cuando los necesita.



¿Y si le damos los datos correctos justo antes de que responda?

R

RETRIEVAL

Recupera los fragmentos
más relevantes de tus documentos

A

AUGMENTED

Añade ese contexto
al prompt del LLM

G

GENERATION

El LLM genera la respuesta
usando solo ese contexto

Fase de Indexación — preparar la biblioteca

Ocurre UNA VEZ (o al añadir documentos nuevos) — no en cada consulta

1



Cargar documentos

PyPDFLoader /
TextLoader
Extrae texto de PDFs y
TXTs
página por página

2



Chunking

RecursiveCharacterText
Splitter
chunk_size = 512
chunk_overlap = 64

3



Embeddings

omic-embed-text via
Ollama
Texto → vector 768
dims
1 llamada por chunk

4




Guardar en Vector DB

ChromaDB en disco
vector + texto +
metadata
persiste entre
sesiones

LangChain orquesta todo el pipeline. uv gestiona el entorno. Docker corre Ollama.

Fase de Consulta — el viaje de una pregunta

Ocurre en tiempo real, en menos de 2 segundos, cada vez que alguien pregunta




💬 "Según el convenio colectivo (pág. 4), los empleados con contrato indefinido tienen 25 días laborables." 📎 Fuente: nexus_convenio.pdf

Mapa completo del sistema RAG

MAPA COMPLETO — SISTEMA RAG

FASE 1 — INDEXACIÓN (una vez)



FASE 2 — CONSULTA (cada pregunta, en tiempo real)



El System Prompt — la instrucción crítica

Tres líneas que separan un chatbot que alucina de uno que no

```
chain.py

RAG_PROMPT = ChatPromptTemplate.from_messages([
    ("system",
     """Eres un asistente experto.

     Responde ÚNICAMENTE con el
     contexto proporcionado.

     Si no está, di que no lo sabes.

     Cita siempre la fuente."""),
    ("human", "{question}")
])
```



Solo usa lo que está en los documentos



Si no sabe → lo dice, no lo inventa



Siempre cita la fuente exacta



Sin esto el LLM ignora el contexto y alucina

Stack tecnológico — qué usamos y por qué

Todo local · Todo gratuito · Todo open source

uv

Gestor de entorno Python

Estándar 2026, rápido y reproducible

ChromaDB

Vector Database

Sin servidor, guarda en disco

Ollama

Servidor LLM local

ChatGPT en tu máquina, sin API key

LangChain

Framework RAG

Orquesta todo el pipeline

Llama 3.2

Modelo de lenguaje (LLM)

Open source Meta, corre con 8GB RAM

Chainlit

Interfaz de chat

Streaming + fuentes nativas para LLMs

nomic-embed


Modelo de embeddings

Local, gratuito, 768 dimensiones

Docker

Contenedor para Ollama

Reproducible en cualquier máquina



DEMO EN VIVO

Nexus Solutions SL — Política de empresa + Convenio colectivo

1. ¿Cuántos días de vacaciones con contrato indefinido?
 2. ¿Qué pasa con mis vacaciones si me pongo enfermo?
 3. ¿Cuánto cobro de dietas en viaje internacional?
- ⚠ Esta no la va a saber — y lo va a decir.

La misma pregunta. Dos resultados.

Tu sistema RAG



Según el convenio colectivo (pág. 4), los empleados con contrato indefinido tienen 25 días laborables de vacaciones.



Fuente: nexus_convenio.pdf — Pág. 4

*Puedes verificarlo.
La fuente está ahí.*



Gemini (sin RAG)



Nexus Solutions ofrece 22 días de vacaciones según su política interna de recursos humanos.



Sin fuente — dato inventado

*No hay forma de verificarlo.
Y suena igual de convincente.*



Limitaciones reales de los LLMs

Antes de hablar de RAG, hay que entender qué no puede cambiar RAG



Alucinación estructural

El LLM siempre generará texto plausible. RAG reduce el problema pero no lo elimina si el contexto es ambiguo.



Conocimiento estático

El modelo no aprende de nuevas consultas. El conocimiento queda fijo en el entrenamiento.



Lost in the middle

Los LLMs prestan menos atención al contexto del medio del prompt. Los chunks importantes van al inicio o al final.



Razonamiento multi-hop

Combinar información de muchos documentos distantes es difícil. RAG básico no lo resuelve bien.

Limitaciones reales de RAG

Conocer los límites es parte de usarlo bien

01 Basura entra, basura sale

Si tus documentos están desactualizados o mal escritos, RAG no lo arregla. La calidad de los docs es todo.

02 Reduce aluc., no las elimina

Si el contexto es ambiguo o contradictorio, el LLM puede seguir fallando. No es infalible.

03 Malo para síntesis global

Preguntas que requieren leer 100 documentos a la vez no funcionan bien. RAG es bueno para preguntas puntuales.

04 Añade latencia

Cada consulta tarda 1-2 segundos más que un LLM directo. En producción hay que gestionarlo.

Conocer los límites es parte de usarlo bien.

Gracias por vuestra atención.

Todo el código disponible en:

<https://github.com/Marizqdo/RAG-demo>

Mar Izquierdo Vaquer

uv

Ollama

Llama 3.2

ChromaDB

LangChain

Chainlit

Docker